

Métricas · Golden Signals (Google SRE)

- Latência: tempo de resposta (p50, p95, p99)
- Tráfego: requests por segundo
- Erros: taxa de 5xx
- Saturação: CPU, memória, conexões
- Stack: Prometheus + Grafana

GLOSSÁRIO

p50 (mediana): metade dos requests respondem mais rápido que esse valor.

p99: só 1% dos requests é mais lento. Esse 1% costuma ser o pior usuário.

p95: 95% dos requests respondem nesse tempo ou menos. Os 5% piores estão fora.

Por que percentil? média esconde outliers. p99 mostra a experiência do pior caso.

Tracing Distribuído



OpenTelemetry + Jaeger / Zipkin. Sem isso, debug em distributed é chute.